

Лабораторная работа 3. ОБУЧЕНИЕ С УЧИТЕЛЕМ. ЗАДАЧА КЛАССИФИКАЦИИ

1. Изучение примеров. Изучите примеры: [Lab3_Ex1_Basic_Classifiers.ipynb](#), [Lab3_Ex2_LogisticRegr_HotCode.ipynb](#), [Lab3_Ex3_Naive_Bayes.ipynb](#), [Lab3_Ex4 Imbalance.pdf](#), [Lab3_Ex5 ClassificationModel.ipynb](#)

2. Загрузка и подготовка данных.

- В соответствии с индивидуальным вариантом загрузите предобработанный датасет в формате CSV для решения задачи классификации.
- Выделите целевой признак и предикторы. Определить тип задачи классификации (бинарная или мультиклассовая).
- Проверьте баланс классов. В случае дисбаланса классов проведите их балансировку (см. [Lab3_Ex4 Imbalance.pdf](#)).

Проблема дисбаланса классов решается **только на обучающей выборке (train)**. Валидационная (val) и тестовая (test) выборки **не балансируются**, они должны сохранять исходное (реальное) распределение классов.

- При разделении данных на обучающую и тестовую выборки используйте два метода:

– **Метод отложенной выборки hold-out (train/val/test)** с учётом *стратификации*¹, чтобы выборки сохраняли относительную пропорцию классов. Рекомендуемое соотношение: **60% – train, 20% – val, 20% – test** (или **70/15/15** для небольших наборов данных). Для получения трёх выборок выполните два последовательных разбиения с параметром **stratify=y** на каждом шаге.

Изучите самостоятельно: онлайн-документация, раздел [train_test_split в Sklearn] https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html

– **Метод k-fold² (кросс-валидация).**

Изучите самостоятельно: онлайн-документация, [Кросс-валидация] https://scikit-learn.org/stable/modules/cross_validation.html

онлайн-документация, [k-fold] https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.KFold.html

онлайн-документация, [функция cross_val_score] https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.cross_val_score.html

При кросс-валидации в задачах классификации можно использовать StratifiedKFold вместо KFold, чтобы в каждом фолде сохранялась пропорция классов (особенно важно при дисбалансе)

Или https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.cross_val_score.html#sklearn.model_selection.cross_val_score

можно использовать cross_val_score с параметром cv=StratifiedKFold(10)

¹¹Стратифицированная выборка (stratified sampling), это делает функция test_train_split, когда устанавливаете параметр stratify для меток.

²Основной класс для использования — KFold, также есть функция cross_val_score, которая позволяет проще применить кросс-валидацию при моделировании алгоритмов ML

Кросс-валидацию проводите с использованием **10 фолдов**. Для каждого фолда выведите значения метрик оценки качества (Accuracy, Precision, Recall, F1) в виде таблицы (можно без Кappa и AUC), а так же средние значения и стандартное отклонение метрик по всем фолдам как на рисунке 1.

	Accuracy	AUC	Recall	Prec.	F1	Kappa
Fold						
0	0.8929	0.8722	0.8000	0.8889	0.8421	0.7614
1	0.8571	0.8444	0.8000	0.8000	0.8000	0.6889
2	0.9286	0.9444	1.0000	0.8333	0.9091	0.8511
3	0.8929	0.8722	0.8000	0.8889	0.8421	0.7614
4	0.8929	0.8944	0.9000	0.8182	0.8571	0.7717
5	0.9643	0.9722	1.0000	0.9091	0.9524	0.9239
6	0.8214	0.8167	0.8000	0.7273	0.7619	0.6196
7	0.8214	0.8167	0.8000	0.7273	0.7619	0.6196
8	0.7857	0.7667	0.7000	0.7000	0.7000	0.5333
9	0.8214	0.7944	0.7000	0.7778	0.7368	0.6023
Mean	0.8679	0.8594	0.8300	0.8071	0.8163	0.7133
Std	0.0531	0.0618	0.1005	0.0705	0.0749	0.1159

Рисунок 1

3. Решение задачи классификации.

- Решите задачу классификации на ваших данных с использованием следующих классификаторов из Scikit-learn:
 - [Logistic Regression](#).
 - [kNN](#). Исследуйте различные методы расстояния и их влияние на классификацию.
 - [Naive Bayes](#).
 - [SVM](#), в том числе с ядерными функциями (Linear Kernel, Polynomial Kernel, RBF Kernel, Sigmoid Kernel, Exponential Kernel).
- При необходимости подобрать гиперпараметры для соответствующего классификатора тремя способами (GridSearchCV; RandomizedSearchCV; фреймворк Optuna).
- Постройте итоговую модель классификаторов (см. [Lab3_Ex5 ClassificationModel.ipynb](#)).

4. Визуализация. Постройте графики для визуализации результатов классификации, чтобы показать, как работают классификаторы. Например, представьте график, демонстрирующий влияние изменения k на точность модели kNN. Для бинарной классификации постройте ROC curve.

5. Оценка качества моделей. Вычислите значения метрик оценки качества для обученных моделей классификации: F1, Accuracy, Precision, Recall, матрица ошибок (confusion matrix), ROC AUC score. Поясните ошибки первого и второго рода.

6. Реализация пользовательских функций.

- Самостоятельно реализуйте вычисление следующих метрик оценки качества модели классификации: Accuracy, Precision, Recall, F1, матрица ошибок.
- Поместите пользовательские функции в отдельный файл³ и подключите его к основной программе как библиотеку функций.

7. Реализация алгоритма классификатора kNN.

- Самостоятельно разработайте и реализуйте классификатор на основе алгоритма kNN в контексте реализации Scikit-learn.
- Поместите разработанный классификатор kNN в отдельный файл и подключите его к основной программе как библиотеку алгоритмов ML.
- Создайте таблицу (объект DataFrame) и выведите в них наименования используемых классификаторов и значения вычисленных метрик оценки качества как с использованием Scikit-learn (Образец 1).

Образец 1

	Train Data				Test Data			
Классификатор	F1	Accuracy	Precision	Recall	F1	Accuracy	Precision	Recall
kNN из Sklearn	0.XX	0.XXXX	0.XXXX	0.XXXX	0.XX	0.XXXX	0.XXXX	0.XXXX
программный kNN								

Указания к выполнению:

1). Исследование алгоритма kNN.

Изучите теоретические основы алгоритма kNN, включая:

- принцип работы алгоритма;
- методы вычисления расстояния между точками (например, евклидово, манхэттенское);
- влияние гиперпараметра k на производительность модели kNN.

2). Реализация алгоритма.

Напишите класс для классификатора kNN. Основные функции должны включать:

- метод для обучения модели;
- метод для предсказания класса для новых данных;
- расчет расстояния между точками;
- возможность выбора количества ближайших соседей k.

3). Сравните производительность разработанного классификатора с эталонным классификатором kNN из Scikit-learn.

³Этот файл разработан при выполнении **Лабораторной работы №2**.

8. Создание таблицы результатов.

- Создайте две таблицы (объект DataFrame) и выведите в них наименования используемых классификаторов и значения вычисленных метрик оценки качества как с использованием Scikit-learn, так и пользовательских функций (Образец 2 и Образец 3).

- Убедитесь, что при выводе значений предусмотрено необходимое количество знаков после запятой (см. Образец 2 и Образец 3).

Образец 2

	Train Data				Test Data			
Классификатор	F1	Accuracy	Precision	Recall	F1	Accuracy	Precision	Recall
Logistic Regression	0.XX	0.XXXX	0.XXXX	0.XXXX	0.XX	0.XXXX	0.XXXX	0.XXXX
...								

Образец 3

	Метод hold-out (test)				Метод k-fold (кросс-валидация)			
Классификатор	F1	Accuracy	Precision	Recall	F1 (среднее $\pm$ std)	Accuracy (среднее $\pm$ std)	Precision (среднее $\pm$ std)	Recall (среднее $\pm$ std)
Logistic Regression	0.XX	0.XXXX	0.XXXX	0.XXX X	0.XX	0.XXXX	0.XXXX	0.XXXX
...								

9. Вывод. Напишите вывод о выполненной Лабораторной работе №3, в котором выберите лучшую модель классификации и обоснуйте свое решение.