

Лабораторная работа 5. ОБУЧЕНИЕ БЕЗ УЧИТЕЛЯ. ЗАДАЧА КЛАСТЕРИЗАЦИИ

1. Изучение примеров.

Изучите примеры: [Lab5_ML Ex1 Base Clustering.ipynb](#), [Lab5_ML Ex2 Метод кластеризации_k_means.ipynb](#), [Lab5_ML_Ex3 K_means_Hierarch.ipynb](#)

2. Загрузка и подготовка данных.

2.1. Сгенерировать 3 датасета с использованием функции¹ `make_classification`² и 2 датасета с использованием функции `make_blobs`³ (см. [Lab5_ML Ex1 Base Clustering.ipynb](#)). Данные необходимо сгенерировать так, чтобы на них можно было получить хорошее качество кластеризации. Количество кластеров должно быть различным и составлять не менее трёх.

2.2. В соответствии с индивидуальным вариантом загрузите предобработанный датасет в формате CSV для задачи классификации. Удалите метку класса.

3. Решение задачи кластеризации.

3.1. Реализовать следующие алгоритмы кластеризации на синтетических данных: k-means, иерархическая кластеризация, DBSCAN, EM-алгоритм, Affinity Propagation.

3.2. Реализовать следующие алгоритмы кластеризации на данных для задачи классификации: k-means, DBSCAN, EM-алгоритм, Affinity Propagation.

3.3. Для соответствующего алгоритма кластеризации (используемых в п. 3.1 и п. 3.2) подобрать оптимальные гиперпараметры. В случае алгоритма k-means используйте «метод локтя» и график силуэтов.

3.4. Провести визуализацию работы всех алгоритмов кластеризации. Если это возможно, то вывести номер кластера. Опишите качество кластеров по их внешнему виду.

3.5. Вывести номер кластера, создав дополнительный столбец в датасете для задачи классификации. Найдите характеристики каждого из кластеров с помощью библиотеки Pandas (см. [Lab5_ML Ex2 Метод кластеризации_k_means.ipynb](#)) и опишите каждый найденный класс.

4. Оценка качества моделей. Каждый реализованный алгоритм кластеризации оцените 2 внешними и 2 внутренними метриками оценки качества.

¹ `make_classification` и `make_blobs` — функции из библиотеки `Sklearn.datasets` для генерации синтетических наборов данных для задач классификации и кластеризации соответственно.

² Функция `make_classification` генерирует случайный набор данных для классификации, который можно использовать для тестирования алгоритмов ML. Можно настроить количество классов, признаков и образцов.
https://scikit-learn.org/stable/modules/generated/sklearn.datasets.make_classification.html

³ Функция `make_blobs` создает набор данных с определенным количеством кластеров, где каждый кластер имеет свои центры. Это подходит для задач кластеризации.
https://scikit-learn.org/stable/modules/generated/sklearn.datasets.make_blobs.html

5. Реализация алгоритма кластеризации k-means.

5.1. Самостоятельно разработайте и реализуйте алгоритм кластеризации k-means с возможностью подсчета суммы квадратов расстояний между точками и соответствующими центроидами.

5.2. Поместите разработанный алгоритм кластеризации k-means в существующий файл библиотеки алгоритмов ML и подключите его к основной программе.

5.3. Проведите кластеризацию двух сформированных датасетов (см. п. 2.1, для k-means и любой другой) и датасета для классификации с использованием собственной реализации алгоритма k-means и k-means из библиотеки Scikit-learn.

5.4. Произведите визуализацию построенных моделей и покажите распределение кластеров.

5.5. Выполните оценку качества полученных моделей кластеризации. Сравните полученные результаты (Образец 1).

Образец 1

	Внутренние метрики		Внешние метрики	
Алгоритм ML	Y1	Y2	Y3	Y4
k-means из Sklearn	0.XX	0.XX	0.XX	0.XX
программный k-means				

6. Создание таблицы результатов.

Создайте таблицу, выведите в ней наименования используемых алгоритмов кластеризации, наименования и значения вычисленных метрик оценки качества (Y1 и т.д.) для синтетических данных и датасета для задачи классификации (Образец 2).

Образец 2

	Внутренние метрики		Внешние метрики	
Алгоритм ML	Y1	Y2	Y3	Y4
...	0.XX	0.XX	0.XX	0.XX
...				

7. Вывод.

Напишите развернутый вывод по итогам выполненной **Лабораторной работе №5**. Укажите, какая модель кластеризации показала наилучшие результаты для датасета задачи классификации и для синтетических данных. Обоснуйте свой выбор на основе полученных метрик и визуального анализа.

По результатам выполнения **Лабораторной работе №5** разработайте интеллект-карту, которая содержит решение задачи кластеризации. Полученное изображение вставьте в файл .ipynb.